

Защитная речь по слайдам

Проект: «Линейная регрессия для прогноза цены автомобиля» (Auto.ru, 12 433 машин)

Регламент: 15 минут на доклад, 7 минут на вопросы.

Структура файла: для каждого слайда дано (1) что говорить, (2) что отвечает каждый тест/метрика, (3) почему мы перешли к следующему шагу, (4) готовые ответы на ожидаемые вопросы.

Слайд 1 — Титул

Что говорить (15 секунд)

«Добрый день. Тема нашей работы — линейная регрессия для прогноза цены поддержанного автомобиля по данным Auto.ru. Команда: я Никита — капитан, со мной Лиза, Маша и Андрей. Расскажу, что мы сделали на втором этапе.»

Слайд 2 — Роли, цель, задачи

Что говорить (50 секунд)

«Я как капитан взял на себя основные аналитические задачи. Маша помогала с данными и контролем целостности, Лиза — с визуализацией и диагностикой, Андрей — с постановкой и интерпретацией результатов.»

«Цель: построить качественную интерпретируемую регрессионную модель цены автомобиля, оценить её метрики и выявить ключевые факторы, включая неочевидные зависимости.»

«Задачи 2 этапа: расширенный EDA с корреляциями, PCA и кластеризацией; базовая OLS-модель; диагностика её предпосылок; улучшение через feature engineering, WLS, сегментацию; финальное сравнение на out-of-sample test.»

«Критерии успеха: $R^2_{adj} > 0.80$ на test; все коэффициенты значимы ($p < 0.05$) после backward; VIF под контролем; корректные стандартные ошибки.»

Возможные вопросы

В: Почему такая цель, а не предсказать категорию или ранжировать?

О: Цена — непрерывная переменная, регрессия — естественный выбор. Линейная — потому что по конспекту курса; даёт интерпретируемые коэффициенты в процентах.

В: Откуда взялся порог $R^2_{adj} = 0.80$?

О: Это типовой ориентир для регрессии на хорошо собранных табличных данных по ценам. На сырой цене обычно достигается R^2 0.6-0.7, на $\ln(\text{price})$ с правильной спецификацией — 0.8+.

Слайд 3 — Данные

Что говорить (50 секунд)

«Парсер на Python (Playwright + requests), 7 прогонов в мае. Получили 12 433 машины — частные продажи, регион РФ, пробег от 50 тысяч километров. Из 80 исходных признаков отобрали те, у которых заполненность выше 80% — это 23 числовых и 4 главных категориальных.»

«Средний возраст 15 лет, пробег 160 тыс. км, мощность 166 л.с. Распределение по топливу — 86% бензин, по КПП — 44% автомат, по приводу — 51% передний. Заполненность числовых после фильтра — 96%.»

Что было в предобработке (на случай вопросов — у нас этого нет отдельного слайда!)

- Дедупликация по URL объявления

- Нормализация категорий: lower() + strip, маппинг RU → canonical (например, «Передний» и «передний» → один уровень)
- Пропуски: медианная импутация по train (числовые с fill ≥ 80%)
- Выбросы цены: фильтр по квантилям 0.5%-99.5% (убрали единичные Bentley и «помойки» за 10 тыс.)
- Логарифмирование цены: ln(price)
- Train/test split: 80/20, random_state=42, размеры — 9 480 / 2 370 наблюдений

Возможные вопросы

В: Машинам до 56 лет, это реалистично?

О: Да, это ретро-автомобили (старше 1970). Их немного, но они есть в выборке. На out-of-sample тесте они не доминируют.

В: Почему именно auto.ru, а не drom или avito?

О: Auto.ru даёт структурированные карточки с большим числом технических характеристик, что важно для построения регрессии. Avito имеет более «свободный» формат описаний.

В: Где сама предобработка показана?

О: Это блок 5 нашего рабочего ноутбука — здесь упоминаю кратко: дедуп по URL, медианная импутация для числовых с fill ≥ 80%, логарифм цены, train/test split 80/20.

Слайд 4 — Распределение цены и ln(price)

Что говорить (40 секунд)

«Слева — сырая цена. Видно сильную правую скошенность: основная масса до 2 миллионов, длинный хвост премиум-машин до 14 миллионов. Skewness > 4.»

«Справа — логарифм цены, наложена нормальная огибающая $N(13.85, 1.20)$. После логарифмирования распределение почти симметрично — skewness падает с 4.1 до 0.1.»

«Почему логарифм: цены имеют мультипликативную природу — рост в N раз эквивалентен сдвигу $\ln$ на $\ln(N)$. Это даёт коэффициенты в процентах. Например, $\beta = -0.10$ при age значит, что каждый год машина дешевеет на $\approx 10\%$.»

Возможные вопросы

В: Почему именно ln, а не sqrt или другая степень?

О: Логарифм — частный случай преобразования Бокса-Кокса при $\lambda=0$. Для цен он почти всегда оптимален; формально можно подобрать λ , но обычно он выходит близко к 0.

В: Jarque-Bera для ln(price) всё равно отвергает нормальность?

О: Да, при $n=12433$ любой тест нормальности почти всегда отвергает. Смотрим на skew (=0.1) и форму распределения — практически симметрично, для регрессии этого достаточно через CLT.

Слайд 5 — Корреляции и VIF

Что говорить (60 секунд)

«Слева — топ-10 признаков по |Pearson r| с ln(price). Сильнейшие: rear_track_width (0.756), front_track_width (0.747), width (0.730), engine_power_hp (0.674), weight_curb (0.686). Но рядом колонка VIF — и у первых пяти она 10-27. Это сигнал жёсткой мультиколлинеарности.»

«Справа — Pearson r против Spearman r для всех признаков. Зелёные (Spearman) почти везде длиннее синих — признаки имеют монотонную нелинейность. Самая большая разница у tax_amount ($\Delta = 0.22$): Pearson r = 0.51, Spearman r = 0.73. Это значит налог связан с ценой ступенчато — через региональные пороги по л.с.»

Что значат метрики

Pearson r : линейная корреляция (-1; +1). Ловит только линейную связь.

Spearman ρ : ранговая корреляция, ловит монотонные (в т.ч. нелинейные) связи.

Частная корреляция: $r(x_j, y \mid \text{остальные})$ — связь после контроля на другие предикторы. Очень мала (0.005-0.16), потому что многие признаки дублируют друг друга.

VIF (Variance Inflation Factor): $1/(1 - R^2_j)$, где R^2_j из регрессии x_j на остальные предикторы. VIF=1 — нет коллинеарности, VIF>5 — заметная, VIF>10 — критичная.

$\Delta = |\rho| - |r|$: индикатор нелинейности. $\Delta > 0.05 \rightarrow$ монотонная нелинейность, кандидат на логарифм/степень.

Возможные вопросы

В: Почему частные корреляции почти нулевые у топ-признаков с большим Pearson r ?

О: Потому что эти признаки сильно коррелированы между собой. Например, width имеет Pearson $r=0.73$ с ценой, но частную всего 0.007 — после контроля на rear_track_width и engine_power_hp width уже почти ничего не добавляет.

В: Что делать с признаками VIF > 10?

О: Удалить или заменить на их линейную комбинацию. Это и есть смысл нашего отбора в блоке 8.

В: Spearman > Pearson для всех — это нормально?

О: Да, для большинства признаков это означает наличие монотонной нелинейности. Поэтому мы потом добавляем age^2 , $\ln_mileage$ и т.д. — feature engineering.

Слайд 6 — Корреляции по группам

Что говорить (40 секунд)

«Разбили 23 признака на 5 смысловых групп. Внутри "Габариты" — корреляции 0.85-0.92 практически между всеми: длина, ширина, колея, колёсная база. Все они меряют один латентный фактор — размер машины. Аналогично "Двигатель": `engine_power_hp` ↔ `max_torque_nm` = 0.88.»

«Справа — средняя `|corr|` между группами. "Двигатель" и "Габариты" переплетены на 0.48 — большая машина обычно = мощный двигатель. "Расход" почти не коррелирует ни с чем (0.05-0.11) — он сам по себе.»

Вывод этого слайда

Подтверждается гипотеза: множество признаков измеряют одно и то же. Простое включение их всех в OLS вызовет нестабильность оценок через мультиколлинеарность.

Возможные вопросы

В: Почему именно average linkage в кластеризации (показано на следующем слайде)?

О: Average linkage устойчиво к выбросам и даёт сбалансированные кластеры. Альтернативы (complete, single) могут давать «цепочки» или жёсткие кластеры.

Слайд 7 — PCA-биplot

Что говорить (60 секунд)

«Это биplot главных компонент. Точки — машины, окрашены по квартилям цены: синие Q1 — дешёвые, красные Q4 — дорогие. Стрелки — это 23 признака, спроецированные на плоскость двух главных компонент. Первые 2 компонента объясняют 60% общей дисперсии.»

«PC1 (47%) идёт вправо — туда смотрят все размерные и мощностные признаки: ширина, колея, мощность, момент, длина, объём двигателя. Это ось "размер + мощность". Красные дорогие машины уехали по ней вправо.»

«PC2 (13%) идёт вверх — туда смотрят возраст, число владельцев, пробег. Это ось "возраст и износ", ортогональная размеру. То есть возраст и размер — независимые сигналы.»

Что такое PCA в одной фразе

PCA ищет новые ортогональные оси (PC1, PC2, ...) — линейные комбинации исходных признаков, упорядоченные по убыванию объяснённой дисперсии. Это поворот системы координат, при котором первые оси максимально растягивают данные.

Что такое биplot

Биplot — точки наблюдений в новых координатах + стрелки исходных признаков (loadings). Угол между стрелками = корреляция в полном пространстве; параллельные стрелки = коррелированные признаки; ортогональные = независимые.

Возможные вопросы

В: Почему именно 2 компонента, а не 3 или 10?

О: `n_components=2` — для визуализации, дальше нельзя нарисовать. Для самого моделирования мы НЕ используем PC — мы оставляем исходные интерпретируемые признаки.

В: Где здесь PCR (Principal Component Regression)?

О: Мы его не делаем сознательно. PCA для нас — диагностический инструмент структуры данных. PCR заменил бы интерпретируемые признаки на абстрактные PC1, PC2 — мы бы потеряли возможность сказать «возраст уменьшает цену на 10% в год».

В: Параллельные стрелки в правой части — это что?

О: Кластер размерных признаков. Они почти параллельны в 2D, но в полном 23-мерном пространстве угол между ними больше — Pearson r у них 0.75-0.90, не 1.00.

Слайд 8 — Отбор признаков по кластерам

Что говорить (60 секунд)

«Слева сверху — scree plot: для 90% дисперсии нужно 10 компонент, для 95% — 14. Из 23 признаков эффективно используется только 10-14, остальные избыточны.»

«Слева снизу — иерархическая кластеризация по расстоянию $1 - |\text{corr}|$ с порогом 0.20, то есть признаки в одном кластере попарно коррелируют 0.80+. Цветные ветки — кластеры-двойники.»

«Справа — финальный список KEEP. В каждом кластере оставляем "чемпиона" — признак с максимальной $|\text{corr}|$ с $\ln(\text{price})$. Например, `rear_track_width` побеждает в кластере с `front_track_width` и `width`; `max_torque_nm` побеждает над `weight_curb` и `engine_power_hp`.»

«Колонка `communality` показывает, насколько признак вписан в первые 10 РС. Если у одиночки-чемпиона `communality` низкая И `corr_y < 0.15` — выкидываем. Но у нас все важные имеют `communality` 0.82-0.99. Поэтому оставляем 16 признаков.»

Что такое communality

Сумма квадратов нагрузок (loadings^2) данного признака по первым k главным компонентам. Это доля дисперсии конкретного признака, объяснённая этими k компонентами. $\text{Communality}=1 \rightarrow$ признак полностью вписан в первые k РС; $\text{communality}=0 \rightarrow$ его информация в «отброшенных» компонентах.

Возможные вопросы

В: Почему порог 0.80 для кластеризации, а не 0.85 или 0.70?

О: Это эвристика. На 0.85 кластеров было бы больше (меньше двойников), на 0.70 — меньше (агрессивнее отбор). 0.80 — компромисс, при котором отбраковываются явные дубликаты, но сохраняется достаточно разнообразия.

В: Почему `champion` = максимум `corr_y`, а не максимум `communality`?

О: Потому что цель регрессии — предсказать Y . `corr_y` напрямую измеряет полезность для Y , а `communality` — структурную полезность для X .

В: Что если `champion` выбран случайно — `engine_power_hp` проиграл `max_torque_nm` на 0.015?

О: Да, разница мала и в другом прогоне могло быть иначе. Это не критично: оба несут одну информацию через `corr` 0.88. Что важно — мы оставили один из них, а не оба.

Слайд 9 — Категориальные признаки

Что говорить (50 секунд)

«Слева — boxplots по 4 категориям против $\ln(\text{price})$. Механика сильно ниже автомата и робота; полный привод выше переднего и заднего; внедорожники, купе, кабриолеты — премиум-сегмент.»

«Справа — формальная проверка. ANOVA для всех 4 факторов отвергает H_0 о равенстве средних — каждая категория несёт значимый сигнал, $p \ll 0.05$.»

«Tukey HSD — попарные сравнения. Для `fuel_type`: все 3 пары значимы. Для `transmission`: 5 из 6, неотличимы автомат и робот. Для `drive_type`: 2 из 3, неотличимы задний и передний — значимо отличается только полный.»

«Практический вывод: для `transmission` можно использовать бинарку `is_manual` (механика vs остальные), для `drive_type` — `is_4wd` (полный vs остальные). Это снижает число параметров.»

Что такое ANOVA и Tukey HSD

ANOVA F-тест: H_0 — средние $\ln(\text{price})$ одинаковы во всех группах категории; H_1 — хотя бы одна группа отличается. Статистика $F = \text{MS}_{\text{between}} / \text{MS}_{\text{within}}$ имеет распределение Фишера. Если F очень велик ($p \ll 0.05$) — отвергаем H_0 .

Tukey HSD: post-hoc тест после ANOVA. Сравнивает все пары групп попарно с поправкой на множественные сравнения (контроль FWER). Для каждой пары даёт meandiff, доверительный интервал и reject (True — пара значимо различается).

η^2 (eta-squared): размер эффекта = $SS_{\text{between}} / SS_{\text{total}}$. Доля дисперсии Y, объяснённая одной категорией изолированно. Аналог R^2 для одного признака.

Возможные вопросы

В: Почему ANOVA отвергает всегда при больших n?

О: Да, при n=9.5k любая, даже малая разница даст значимый F. Поэтому смотрим η^2 для размера эффекта: для transmission $\eta^2 \approx 0.43$ (большой), для fuel_type $\eta^2 \approx 0.09$ (средний).

В: Bonferroni не использовали для коррекции?

О: Tukey HSD сам по себе контролирует FWER (Family-Wise Error Rate) для попарных сравнений после ANOVA. Это более мощный подход для этой задачи, чем Bonferroni.

Слайд 10 — Постановка регрессии и отбор модели

Что говорить (60 секунд)

«Регрессия по конспекту §1.1: $\ln(\text{price}) = \beta_0 + \sum \beta_i x_i + \varepsilon$, где ошибки нормальны с постоянной дисперсией σ^2 . Метод оценки — МНК.»

«Построили три модели для сравнения:»

«Full: все 23 числовых + 4 категории (one-hot). $R^2_{\text{adj}} = 0.80$, но $\text{VIF}=27$ у `rear_track_width` — критическая коллинеарность.»

«Best: 16 KEEP после отбора + категории. R^2_{adj} практически тот же — 0.797. Главное — VIF упал с 27 до 5.4. То есть отбор не потерял качества, только убрал избыточность.»

«Min: backward elimination на Best с порогом $p < 0.05$. Удалили 9 признаков — в основном редкие `body_type` (микровэн, универсал, пикап, лифтбек) и `trunk_volume` с $p=0.077$. R^2_{adj} не упал — эти признаки действительно были бесполезны.»

«Финальная базовая модель — Min, $k=30$ параметров. Это наша точка отсчёта для всех улучшений.»

Что такое backward elimination

Итеративный алгоритм отбора: стартуем с полной модели, на каждом шаге убираем переменную с самым большим p -value (наименее значимую). Останавливаемся, когда все оставшиеся $p < \alpha$ (у нас $\alpha = 0.05$). Жадный алгоритм, не гарантирует глобального оптимума, но даёт разумную модель.

Возможные вопросы

В: Почему backward, а не Lasso?

О: И то и другое работает. Backward — классический пошаговый отбор по p -value (по конспекту §4.2). Lasso занулил бы похожие признаки через L1-штраф. Мы выбрали backward для прозрачности — видно, кого и почему выкинули.

В: VIF падает в 5 раз — мы потеряли информацию?

О: Нет, R^2_{adj} практически не изменился. Информация была в виде дубликатов; мы оставили по одному «представителю» каждого кластера.

В: Почему $\ln(\text{price})$, а не `price`?

О: Из-за правой скошенности (см. слайд 4) и мультипликативной природы цен. Это даёт линейные коэффициенты в логарифмической шкале, интерпретируемые в процентах.

Слайд 11 — Анализ остатков базовой модели

Что говорить (60 секунд)

«Слева — графики остатков. На e vs $\hat{y}$ видно характерную воронку — дисперсия растёт с предсказанием. Это гетероскедастичность. На e vs `age` — небольшая неоднородность по возрасту.»

«Справа сверху — QQ-plot. По центру точки на диагонали, но тяжёлые хвосты — это видно и на гистограмме: $\text{skew}=0.01$ нормальный, но $\text{kurt}=6.4$ значительно выше эталонных 3.»

«Таблица тестов — формальная проверка каждой предпосылки OLS:»

«Jarque-Bera и Shapiro-Wilk отвергают нормальность — но это из-за тяжёлых хвостов и большого n . Для регрессии важна форма ($\text{skew} \approx 0$), и CLT даёт нам нормальность коэффициентов.»

«Breusch-Pagan и White отвергают гомоскедастичность — гетероскед. есть, нужен WLS.»

«Goldfeld-Quandt по возрасту отвергает — дисперсия различается на крайних возрастных группах.»

«RESET $p=2 = 0.96$ — квадратичной нелинейности по $\hat{y}^2$ нет, но RESET $p=2,3 = 6.5e-10$ — кубическая есть. Это сигнал к feature engineering.»

«Durbin-Watson = 2.012 — автокорреляции нет, что логично: это не временной ряд, наблюдения независимы.»

Подробно про каждый тест

Jarque-Bera: H_0 — остатки нормальны. Статистика $JB = (n-m)/6 \cdot (S^2 + (K-3)^2/4) \sim \chi^2(2)$. Отвергаем H_0 , если JB велика.

Shapiro-Wilk: H_0 — выборка из нормального распределения. Более чувствителен на малых n ; на 5000+ почти всегда отвергает.

Breusch-Pagan: H_0 — $D[\epsilon] = \sigma^2$ постоянна. Вспомогательная регрессия $e^2 \sim X$. Статистика $LM = n \cdot R^2_{aux} \sim \chi^2(p-1)$.

White: расширенный BP — во вспомогательную регрессию добавляются квадраты и взаимодействия. Ловит больше типов гетероскеда.

Goldfeld-Quandt: упорядочиваем по подозрительному предиктору, отбрасываем середину, сравниваем дисперсии крайних групп через F-тест.

RESET (Ramsey): H_0 — функциональная форма правильна. Вспомогательная регрессия $y \sim X + \hat{y}^2 + \hat{y}^3 + \dots$. Если коэффициенты при степенях $\hat{y}$ значимы — есть нелинейность.

Durbin-Watson: $DW \approx 2$ — автокорреляции нет. $DW < 1.5$ — положительная (соседние остатки похожи), $DW > 2.5$ — отрицательная.

Возможные вопросы

В: RESET $p=2$ говорит "линейность ОК", а $p=2,3$ отвергает — это противоречие?

О: Нет, это разные тесты. $p=2$ проверяет только квадратичную нелинейность по $\hat{y}^2$. $p=2,3$ добавляет кубический терм $\hat{y}^3$ — и он значим. Значит, в данных есть нелинейность, которая ловится кубическими (или эквивалентно — взаимодействиями) термами. Это и есть наш мотив для добавления mileage^2 , engine_x_age на следующем слайде.

В: Почему JB и Shapiro всё равно отвергают при $\text{skew}=0.01$?

О: Из-за тяжёлых хвостов ($\text{kurt}=6.4$). Тесты чувствительны к ним. Для регрессии важно, что среднее остатков ≈ 0 и форма симметрична — это выполнено. CLT даёт нам асимптотически нормальные коэффициенты.

В: White тест вы написали "вручную" — почему не `sm.het_white`?

О: `sm.het_white` падает с `AssertionError` при наличии one-hot dummy — у бинарной переменной $x^2 = x$, что создаёт коллинеарность в вспомогательной регрессии. Я реализовал White вручную, исключив квадраты dummy.

Слайд 12 — Feature Engineering: $M_{min} \rightarrow M_{fe_back}$

Что говорить (50 секунд)

«Что добавили по гипотезе из диагностики:»

«Ratio-признаки: $\text{hp_per_kg} = \text{engine_power_hp} / \text{weight_curb}$ — физический проху ускорения; $\text{hp_per_liter} = \text{engine_power_hp} / \text{engine_volume}$ — индикатор турбо vs атмосферник; $\ln_weight_curb$ — логарифм для тяжёлого хвоста массы.»

«Центрирование: $\text{age} \rightarrow \text{age_c} = \text{age} - \text{mean}(\text{age})$, $\text{mileage} \rightarrow \text{mileage_c}$. Это убирает artificial multicollinearity между age и age^2 (без центрирования они коррелируют ~ 0.99).»

«Новые нелинейности: age_c^2 , mileage_c^2 , $\ln_mileage$, engine_x_age ($= \text{engine_volume} \times \text{age_c}$).»

«Все 7 новых признаков значимы — $p < 0.005$ у всех. R^2_{adj} вырос с 0.797 до 0.824, AIC улучшился на 1360, BIC — на 1302.»

«Один важный момент: BP стал чуть хуже (1362 → 1482). Это нормально — модель ближе подошла к Y, остатки растянулись по диапазону, BP-тест чувствительнее на них отреагировал. Это и есть сигнал к следующему шагу — WLS.»

Зачем именно ratio-признаки

Сырые `engine_power_hp`, `weight_curb`, `engine_volume` сильно коррелированы (все на одной оси «размер+мощность» из PCA). Если включить их сырыми — VIF взорвётся. Но отношения между ними — `hp/kg`, `hp/литр` — несут другую информацию: удельную мощность, технологичность двигателя. Ratio ортогональны размеру по построению, потому что нормируются на размер.

Зачем центрирование

Без центрирования `age` и `age2` коррелируют ~0.99 (artificial multicollinearity, обе монотонно растут). После `age_c = age - mean`: `age_c` принимает значения от -15 до +41 (среднее = 0), и `age_c2` — чашеобразная функция. Между ними корреляция падает до низкой.

Возможные вопросы

В: Почему BP стал хуже после FE — это плохо?

О: Не плохо, это побочный эффект улучшения модели. Когда модель точнее, остатки лучше «лепятся» к структуре цены, и любая гетероскед. в данных становится виднее. Это мотивирует следующий шаг — WLS.

В: `hp_per_kg = 5.19` — почему такой большой коэффициент?

О: Потому что `hp_per_kg` измеряется в л.с./кг и обычно лежит в диапазоне 0.05-0.15. Большой коэффициент компенсирует малый масштаб признака. Содержательно: увеличение power-to-weight на 0.1 л.с./кг даёт прирост цены $\approx \exp(0.519) - 1 \approx +68\%$. Это эффект «спортивности».

В: `Engine_x_age` — что это?

О: Взаимодействие объёма двигателя и возраста. Гипотеза: большой двигатель в старой машине теряет в цене иначе, чем малый. Признак значим ($p=2.9e-11$), коэффициент отрицательный — большой двигатель быстрее обесценивается с возрастом.

Слайд 13 — WLS: веса наблюдений

Что говорить (40 секунд)

«WLS — это та же линейная регрессия, но каждое наблюдение взвешено на обратную оценку его дисперсии. Делаем двухшагово (FGLS):»

«Шаг 1: после OLS берём $\ln(e^2)$ и регрессируем на предикторы — получаем оценку $\hat{\sigma}^2(x)$ как функцию от X .»

«Шаг 2: веса $w_i = 1/\hat{\sigma}^2(x_i)$. Точки с большой ожидаемой дисперсией получают меньший вес.»

«Слева — распределение весов в log-шкале. Разброс 1-2 порядка — есть точки, которые WLS существенно «принижает» по влиянию.»

«Справа — зависимость веса от прогноза. Веса слегка растут с $\hat{y}$ — это означает, что точки с малой ценой имеют большую дисперсию, и WLS их штрафует.»

«Результат: BP-статистика упала с 1482 до 231 — в 6.4 раза. Гетероскед. не убрана полностью, но существенно снижена. Главное — стандартные ошибки коэффициентов теперь корректны для t-тестов.»

Что такое WLS математически

OLS минимизирует $\sum e_i^2$. WLS минимизирует $\sum w_i \cdot e_i^2$. Веса w_i выбираются так, чтобы взвешенные остатки имели одинаковую дисперсию. При корректной оценке $\sigma^2(x)$: $D[\sqrt{w_i} \cdot e_i] = \text{const}$.

Возможные вопросы

В: Почему именно FGLS, а не сразу HC3-стандартные ошибки?

О: HC3 (Huber-White robust SE) — упрощённая альтернатива, корректирует только SE, не меняя коэффициентов. WLS даёт и корректные SE, и более эффективные оценки β . Это лучший выбор по конспекту.

В: Почему BP не упал до 0?

О: Наша параметрическая модель $\sigma^2(x) = \exp(\gamma X)$ — аппроксимация. Реальная дисперсия может зависеть от X нелинейно или иметь другую структуру. Поэтому BP формально всё ещё отвергает, хотя статистика упала в 6 раз.

В: Большие веса у каких наблюдений?

О: У точек с малой ожидаемой дисперсией, обычно это типичные машины со средней ценой. Малые веса — у крайних случаев (очень дорогих или очень дешёвых), где предсказание менее уверенно.

Слайд 14 — WLS: диагностика

Что говорить (50 секунд)

«Слева — таблица сравнения OLS и WLS по всем метрикам:»

«kurt упал с 6.12 до 4.66 — хвосты стали тоньше, ближе к нормальности.»

«BP в 6 раз меньше — главная победа WLS.»

«RESET p улучшился на 9 порядков (с $1e-11$ до 0.006) — линейность формы стала корректнее.»

«Durbin-Watson стабилен ≈ 2.0 .»

« R^2_{adj} 0.87 у WLS — это на взвешенной шкале, и формально не сопоставимо с R^2_{adj} OLS = 0.82 напрямую. WLS считает R^2 через $\sum w_i \cdot e_i^2 / \sum w_i \cdot (y_i - \bar{y})^2$, что искусственно завышает.»

«Графики справа: исходные остатки OLS имели воронку, взвешенные остатки WLS — облако без структуры. Гетероскед. визуально ушла. QQ-plot WLS — точки практически на диагонали, кроме крайних хвостов.»

Важное предостережение про R^2_{adj} WLS

R^2_{adj} WLS = 0.87 нельзя цитировать в сравнении с OLS R^2 = 0.82 — это разные метрики, на разных шкалах. Для честного сравнения используем out-of-sample R^2 на test (это в блоке про сегментацию).

Возможные вопросы

В: R^2_{adj} 0.87 — это значит модель стала на 5 п.п. лучше?

О: Нет. Это другая метрика на взвешенной шкале. Для честного сравнения смотрим test R^2 — там WLS глобальная даёт 0.81, а лучшая стратегия (сегментация OLS) — 0.84. То есть в реальном предсказании WLS работает хуже, чем сегментация.

В: Зачем тогда WLS, если на тесте он хуже?

О: WLS оптимизирован для корректности стандартных ошибок и доверительных интервалов. Это важно для статистических выводов о значимости коэффициентов. Сегментация — для прогноза. Это два разных инструмента.

В: Почему kurt упал, а skew стал -0.27 (отрицательный)?

О: WLS-взвешивание подтянуло хвосты, но слегка сместило массу влево — это побочный эффект. Для значений β и SE это не критично, главное — гомоскедастичность.

Слайд 15 — Сегментация

Что говорить (60 секунд)

«Гипотеза: гетероскедастичность идёт от того, что данные структурно неоднородны. Битые и на ходу, новые и старые имеют разные "механизмы ценообразования". Проверяем сегментацией.»

«Слева — графики остатков. На полной выборке BP = 1482. У сегмента "на ходу" — почти такой же. У сегмента "битые" BP резко падает до 29 — внутри битых дисперсия гораздо однороднее. По возрасту — тоже снижение.»

«Справа верхняя таблица — самое важное. Для битых машин глобальная модель даёт R^2 = -0.55 на test — это означает, что она хуже, чем "всегда предсказывать среднее". А сегмент-модель даёт R^2 = 0.46. Разница +1.01 — огромный выигрыш именно для битых.»

«Нижняя таблица — стратегии на полном тесте. Лучшая — OLS-сегментация по vehicle_state, R^2 test = 0.842, MAE = 0.34 в ln-шкале ($\approx \times 1.4$ от истинной цены).»

Как работает сегментированная регрессия

1. Train: делим выборку на сегменты по ключу (vehicle_state, возраст). На каждом строим свою OLS со своим backward.
2. Predict: для новой машины смотрим её сегмент → выбираем нужную модель → она предсказывает.
3. Каждая модель видит только свой сегмент, её коэффициенты заточены под него. Например, у битых машин коэффициент ln_mileage = +1.29 (!) — пробег почти не влияет, важен факт повреждения.

Возможные вопросы

В: Почему OLS-сегментация лучше WLS-сегментации на тесте?

О: WLS оптимизирует для train (через веса), а на тесте веса не пересчитываются — поэтому WLS даёт небольшую потерю обобщающей способности. OLS-сегментация — груше и устойчивее на out-of-sample.

В: R^2 = -0.55 у глобальной модели на битых — как это возможно?

О: Отрицательный R^2 означает, что модель хуже бейзлайна «всегда предсказывать среднее». Глобальная модель ожидает, что битая машина стоит как средняя — а она в разы дешевле. Систематическая переоценка → R^2 отрицательный.

В: У вас train R^2 = 0.71 на битых, а test 0.46. Это переобучение?

О: Да, классическое переобучение из-за малой выборки ($n_{\text{train}} = 384$ при $k=17$). Backward отобрал признаки на этой же выборке, часть из них «случайно» сработала. Но даже переобученная сегмент-модель сильно лучше глобальной ($R^2=-0.55$).

В: Битых всего 92 в тесте — статистика устойчивая?

О: Не очень — это ограничение данных. В проде с большей выборкой битых результат был бы стабильнее. Но даже на этой выборке преимущество сегментации очевидно (+1.0 в R^2).

Слайд 16 — Вывод

Что говорить (60 секунд)

«Цель работы — построить качественную регрессионную модель для прогноза цены автомобиля, оценить метрики и выявить ключевые факторы, включая неочевидные зависимости. Цель достигнута.»

«Финальная модель — OLS-сегментация по vehicle_state, с feature engineering и контролем гетероскедастичности через WLS как альтернативу. На out-of-sample test: $R^2 = 0.84$, MAE = 0.34 в ln-шкале (предсказание в среднем в 1.4 раза от истинной цены).»

«Критерии успеха выполнены: $R^2_{adj} > 0.80$ ✓, все коэффициенты значимы ✓, VIF < 6 для содержательных признаков ✓, BP-статистика снижена в 6 раз через WLS ✓, автокорреляции нет ($DW \approx 2$) ✓.»

«Ключевые факторы: возраст (нелинейно, -12% в год), пробег (убывающая отдача), удельная мощность hp_per_kg, размер машины, тип привода и кузова.»

«Неочевидные находки: битые машины требуют отдельной модели — без неё R^2 на них = -0.55; налог связан с ценой ступенчато (Spearman 0.73 vs Pearson 0.51); PCA-полезность не совпадает с регрессионной (fuel_consumption_mixed вписан в основную структуру X, но цену не предсказывает); автомат ≈ робот и задний ≈ передний по Tukey HSD.»

«Спасибо за внимание. Готовы к вопросам.»

Дополнительный блок: общие защитные вопросы

В: Почему 0.84, а не 0.87?

О: 0.87 — это R^2_{adj} WLS-модели на ВЗВЕШЕННОЙ шкале (формула: $1 - \sum w_i \cdot e_i^2 / \sum w_i \cdot (y_i - \bar{y})^2$). Эта метрика искусственно завышена через веса и не сопоставима с обычным R^2 . 0.84 — out-of-sample R^2 на тесте (обычный R^2 на невзвешенных данных), это честная оценка обобщающей способности.

В: Почему вы не использовали Lasso / ElasticNet как основной метод?

О: Lasso/EN — это альтернатива backward elimination, делает то же самое автоматически. Мы выбрали backward для прозрачности — видно, какие признаки и в каком порядке выкинуты, с какими p-value. В реальной работе провели и Lasso для проверки — результаты совпадают для большинства признаков.

В: Почему не gradient boosting / random forest?

О: Это вне рамок курса. Курс — про линейную регрессию и её диагностику. ML-методы дадут более высокий R^2 , но потеряют интерпретируемость («какой признак на сколько меняет цену»).

В: Что бы сделали в следующей итерации?

О: (1) Бок-Сокс для проверки оптимального преобразования y. (2) Сегментацию по другим ключам (бренд, регион). (3) Робастная регрессия (Huber loss) на случай выбросов. (4) Больше данных — особенно по битым (всего 476 в train).

В: Какие ограничения вашей работы?

О: Данные только за один месяц (нет сезонности), регион усреднён по РФ (нет городской дискриминации), нет информации о состоянии (фото, описание), нет учёта торга. Также backward elimination не гарантирует глобального оптимума — это жадный алгоритм.

В: Что значит $DW \approx 2$ для cross-section данных?

О: Durbin-Watson проверяет автокорреляцию остатков в порядке наблюдений. Для временных рядов это критично. У нас не временной ряд — наблюдения собраны по URL объявлений, порядок случаен. $DW \approx 2$ это подтверждает: автокорреляции нет, как и должно быть.

В: Почему n_test различается (2370 vs 2382)?

О: 12 точек с пропусками в категории vehicle_state исключаются из сегментированной стратегии. В глобальной стратегии все 2382 точки.

В: Mileage_c² с делением на 1e5 — зачем?

О: mileage в километрах достигает 1 миллиона. Квадрат был бы 10¹² — численно неустойчиво. Делим на 1e5 для масштабирования: mileage_c² теперь в диапазоне 0-100, коэффициенты читаемы.

В: Skew=0.011, kurt=6.42 — это нормальное распределение?

О: Skew ≈ 0 — да, симметрично. Kurt = 6.4 значительно выше эталонной 3 — есть тяжёлые хвосты. Распределение унимодально и симметрично, но с большей долей крайних значений, чем у нормального. Для регрессии CLT даёт нам нормальность коэффициентов в пределе, поэтому это не критично.

В: Engine_volume × age — почему именно это взаимодействие?

О: RESET-тест показал, что есть нелинейность, не пойманная сырыми признаками. Эмпирически: большой двигатель быстрее теряет в цене с возрастом (дорогое обслуживание старого V8 — никому не нужно). Это взаимодействие значимо при $p=3e-4$.